Graphics Assignment#2

182STG15 이시영

2019/3/13

1.

```
head(diamonds)
```

```
## # A tibble: 6 x 10
##   carat cut       color clarity depth table price     x     y     z
##   <dbl> <ord>     <ord> <ord>   <dbl> <dbl> <int> <dbl> <dbl> <dbl>
## 1 0.230 Ideal     E     SI2      61.5   55.   326  3.95  3.98  2.43
## 2 0.210 Premium   E     SI1      59.8   61.   326  3.89  3.84  2.31
## 3 0.230 Good      E     VS1      56.9   65.   327  4.05  4.07  2.31
## 4 0.290 Premium   I     VS2      62.4   58.   334  4.20  4.23  2.63
## 5 0.310 Good      J     SI2      63.3   58.   335  4.34  4.35  2.75
## 6 0.240 Very Good J     VVS2     62.8   57.   336  3.94  3.96  2.48
```

```
diamonds %>%
  mutate(id = row_number()) %>%
  select(x, y, z, id) %>%
  gather(variable, value, -id) %>%
  ggplot(aes(x = value)) +
  geom_density() +
  geom_rug() +
  facet_grid(variable ~ .) +
  theme_bw()
```

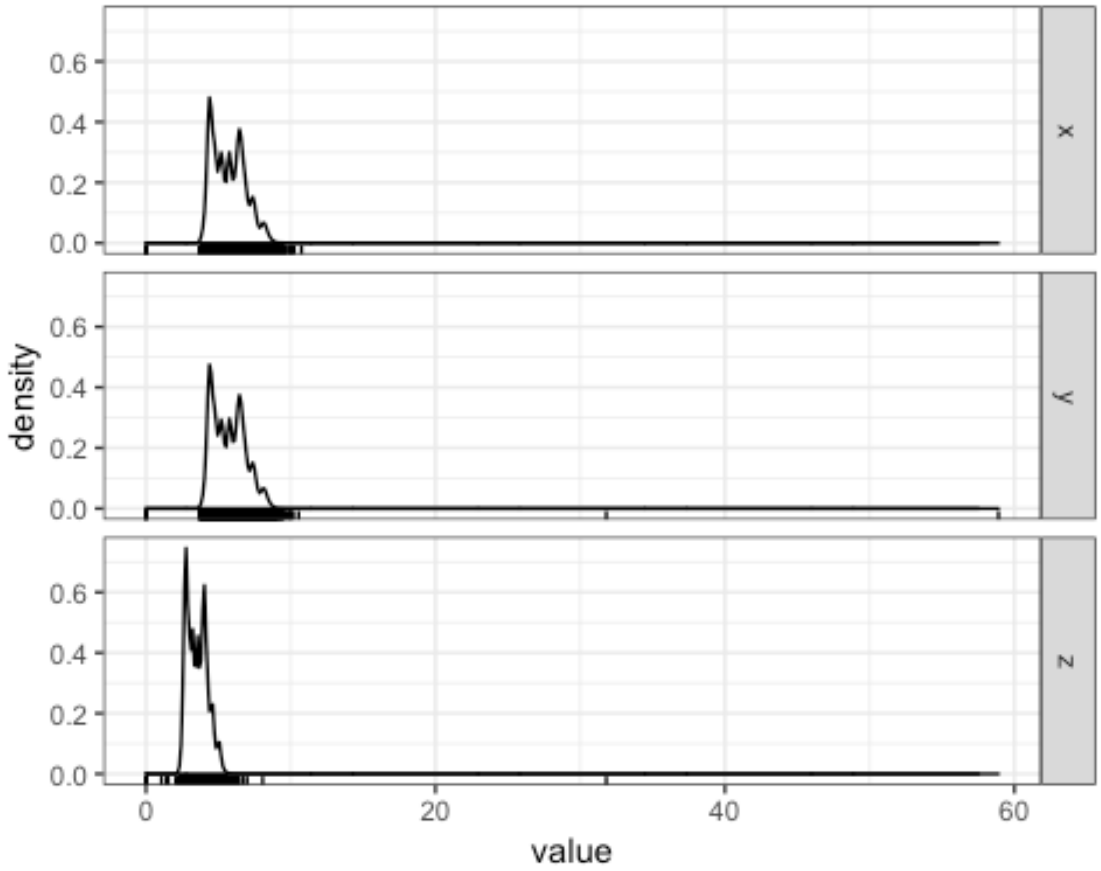

x, y, z 의 분포가 모드 right skewed 임을 알 수 있다. 대부분의 다이아몬드의 크기는 작으나 몇 개의 outlier 들이 존재한다(y & z). z 는 x 와 y 보다는 작은 값들을 가진다.

2.

```
ggplot(diamonds, aes(price)) + geom_histogram(binwidth = 100)
```

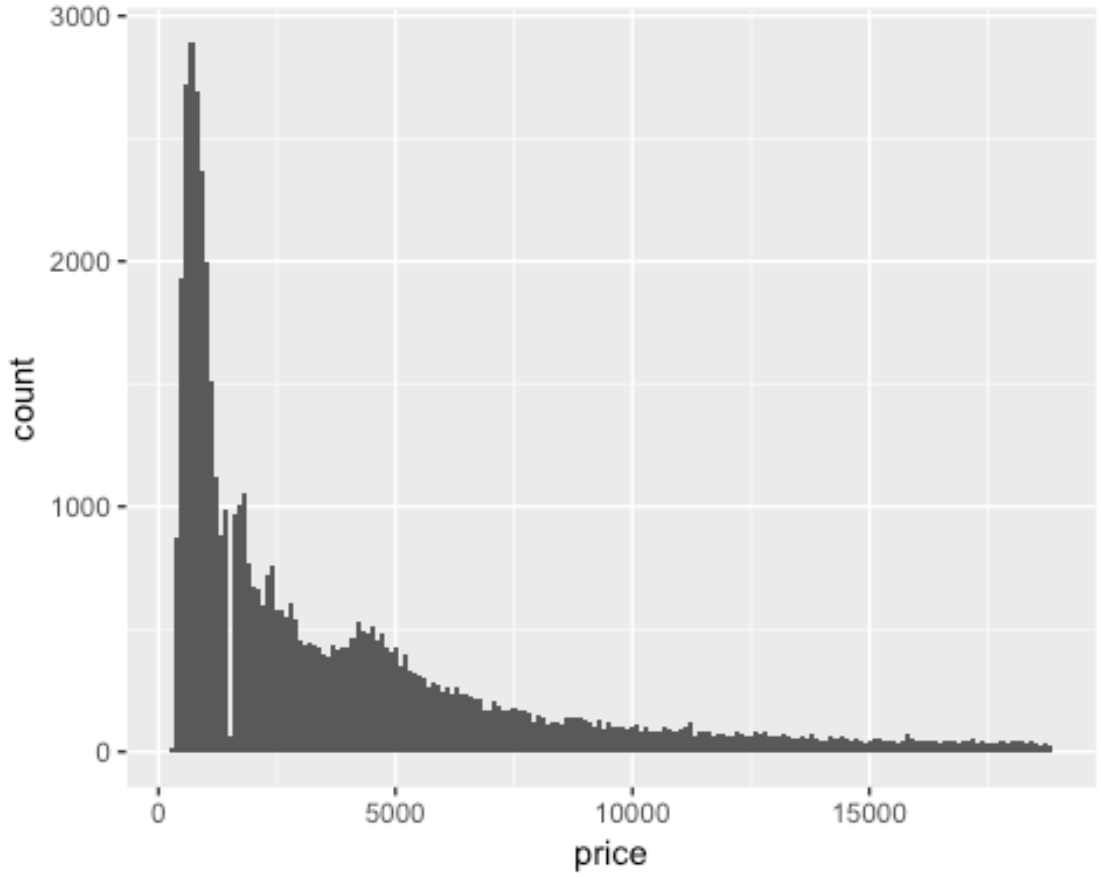

5000 미만의 가격에서 데이터가 몰려있는 것을 관측할 수 있다. 또한 다이아몬드가 존재하지 않는 가격대가 있다. 가격이 5000 미만인 다이아몬드의 정보를 걸러서 다시 히스토그램을 그려보았을 때,

```
ggplot(filter(diamonds, price < 2500), aes(x=price)) + geom_histogram(binwidth = 20)
```

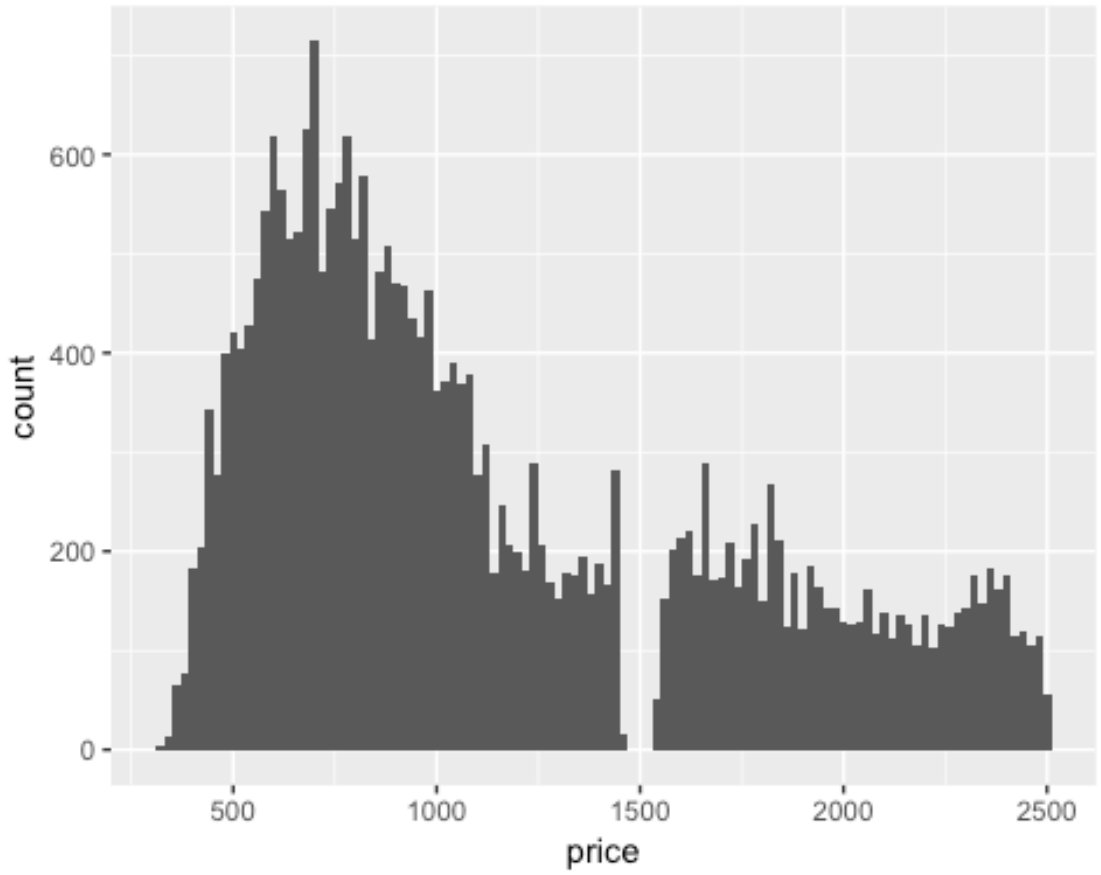

가격이 1500 인 부근에서 다이아모든 관측치가 없는 것을 알 수 있다.

3.

```
##   [1] "0.2"  "0.21" "0.22" "0.23" "0.24" "0.25" "0.26" "0.27" "0.28" "0.29"
##  [11] "0.3"  "0.31" "0.32" "0.33" "0.34" "0.35" "0.36" "0.37" "0.38" "0.39"
##  [21] "0.4"  "0.41" "0.42" "0.43" "0.44" "0.45" "0.46" "0.47" "0.48" "0.49"
##  [31] "0.5"  "0.51" "0.52" "0.53" "0.54" "0.55" "0.56" "0.57" "0.58" "0.59"
##  [41] "0.6"  "0.61" "0.62" "0.63" "0.64" "0.65" "0.66" "0.67" "0.68" "0.69"
##  [51] "0.7"  "0.71" "0.72" "0.73" "0.74" "0.75" "0.76" "0.77" "0.78" "0.79"
##  [61] "0.8"  "0.81" "0.82" "0.83" "0.84" "0.85" "0.86" "0.87" "0.88" "0.89"
##  [71] "0.9"  "0.91" "0.92" "0.93" "0.94" "0.95" "0.96" "0.97" "0.98" "0.99"
##  [81] "1"    "1.01" "1.02" "1.03" "1.04" "1.05" "1.06" "1.07" "1.08" "1.09"
##  [91] "1.1"  "1.11" "1.12" "1.13" "1.14" "1.15" "1.16" "1.17" "1.18" "1.19"
## [101] "1.2"  "1.21" "1.22" "1.23" "1.24" "1.25" "1.26" "1.27" "1.28" "1.29"
## [111] "1.3"  "1.31" "1.32" "1.33" "1.34" "1.35" "1.36" "1.37" "1.38" "1.39"
## [121] "1.4"  "1.41" "1.42" "1.43" "1.44" "1.45" "1.46" "1.47" "1.48" "1.49"
## [131] "1.5"  "1.51" "1.52" "1.53" "1.54" "1.55" "1.56" "1.57" "1.58" "1.59"
## [141] "1.6"  "1.61" "1.62" "1.63" "1.64" "1.65" "1.66" "1.67" "1.68" "1.69"
## [151] "1.7"  "1.71" "1.72" "1.73" "1.74" "1.75" "1.76" "1.77" "1.78" "1.79"
## [161] "1.8"  "1.81" "1.82" "1.83" "1.84" "1.85" "1.86" "1.87" "1.88" "1.89"
## [171] "1.9"  "1.91" "1.92" "1.93" "1.94" "1.95" "1.96" "1.97" "1.98" "1.99"
## [181] "2"    "2.01" "2.02" "2.03" "2.04" "2.05" "2.06" "2.07" "2.08" "2.09"
```

```
## [191] "2.1"  "2.11" "2.12" "2.13" "2.14" "2.15" "2.16" "2.17" "2.18" "2.19"
## [201] "2.2"  "2.21" "2.22" "2.23" "2.24" "2.25" "2.26" "2.27" "2.28" "2.29"
## [211] "2.3"  "2.31" "2.32" "2.33" "2.34" "2.35" "2.36" "2.37" "2.38" "2.39"
## [221] "2.4"  "2.41" "2.42" "2.43" "2.44" "2.45" "2.46" "2.47" "2.48" "2.49"
## [231] "2.5"  "2.51" "2.52" "2.53" "2.54" "2.55" "2.56" "2.57" "2.58" "2.59"
## [241] "2.6"  "2.61" "2.63" "2.64" "2.65" "2.66" "2.67" "2.68" "2.7"  "2.71"
## [251] "2.72" "2.74" "2.75" "2.77" "2.8"  "3"    "3.01" "3.02" "3.04" "3.05"
## [261] "3.11" "3.22" "3.24" "3.4"  "3.5"  "3.51" "3.65" "3.67" "4"    "4.01"
## [271] "4.13" "4.5"  "5.01"
```

carat 은 소수 둘째짜리까지 Count.

```
diamonds %>% filter(carat == 0.99 | carat == 1) %>%
  count(carat)

## # A tibble: 2 x 2
##   carat     n
##   <dbl> <int>
## 1 0.990    23
## 2 1.00   1558
```

1 캐럿 다이아가 0.99 캐럿 다이아에 비해 약 68 배 더 많다.

```
diamonds %>% filter(0.9 <= carat & carat <= 1.1) %>%
  count(carat)

## # A tibble: 21 x 2
##    carat     n
##    <dbl> <int>
##  1 0.900  1485
##  2 0.910   570
##  3 0.920   226
##  4 0.930   142
##  5 0.940    59
##  6 0.950    65
##  7 0.960   103
##  8 0.970    59
##  9 0.980    31
## 10 0.990    23
## # ... with 11 more rows
```

0.9 캐럿, 1.0 이 많이 관측되는 것으로 보아 0.99 와 같이 근사한 값들은 반올림하는 경향이 있는 것 같다.

4.

cut_width()와 cut_number()는 변수를 기준에 따라 그룹으로 나눈다. cut_width()는 나눌시 너비를 이용하고, bin 의 수는 자동으로 계산된다. cut_number()는 bin 수를 지정해야하고 너비는 자동을 계산된다. ggplot 에서 범주는 최대 8 개까지 표현이 가능한다. 따라서 cut_width() 사용 시 조심해야한다.

```
ggplot(diamonds, aes(x=price, color = cut_number(carat, 5))) + geom_freqpoly()
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

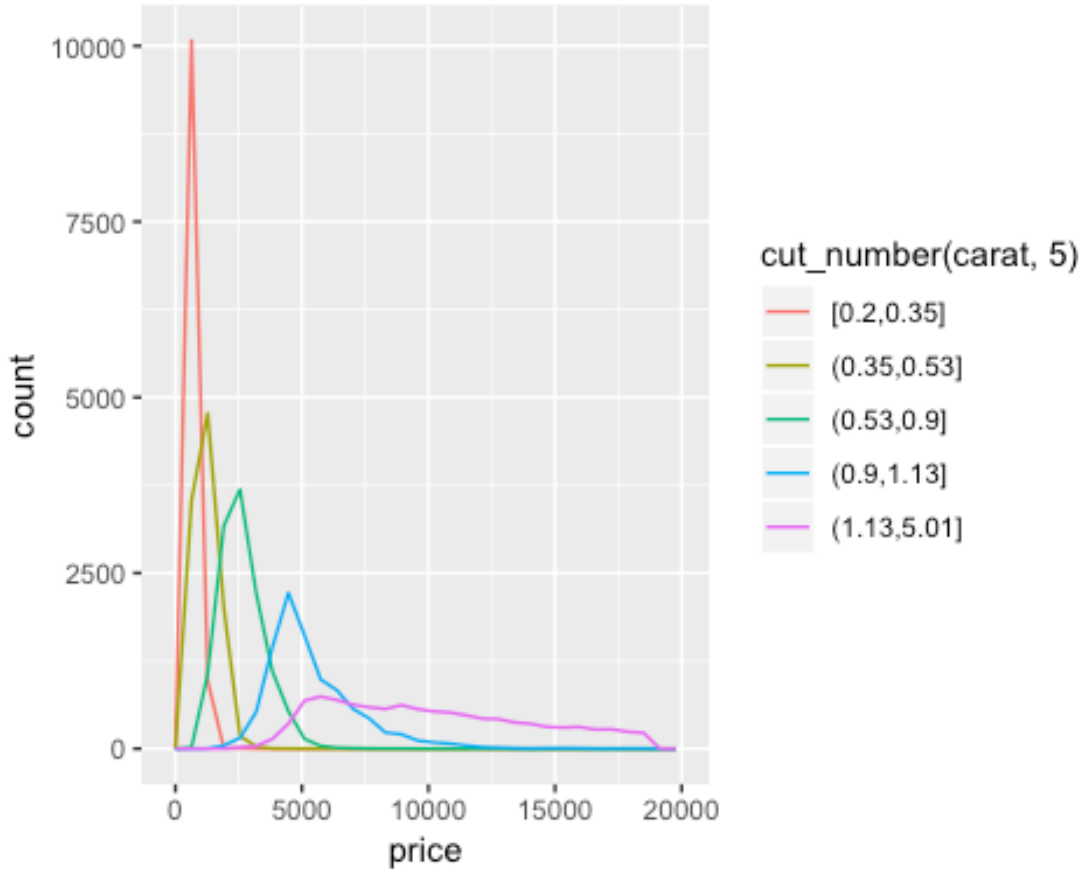

carat 을 5 개의 분위로 나눠서 frequency plot 을 그려보았다. 캐럿수가 클수록 frequency 는 감소하나 가격은 증가한다.

```
ggplot(diamonds, aes(x=price, color = cut_width(carat, 1))) + geom_freqpoly()
 +
  labs(x = 'Price', y = 'Count', color = 'Carat')
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

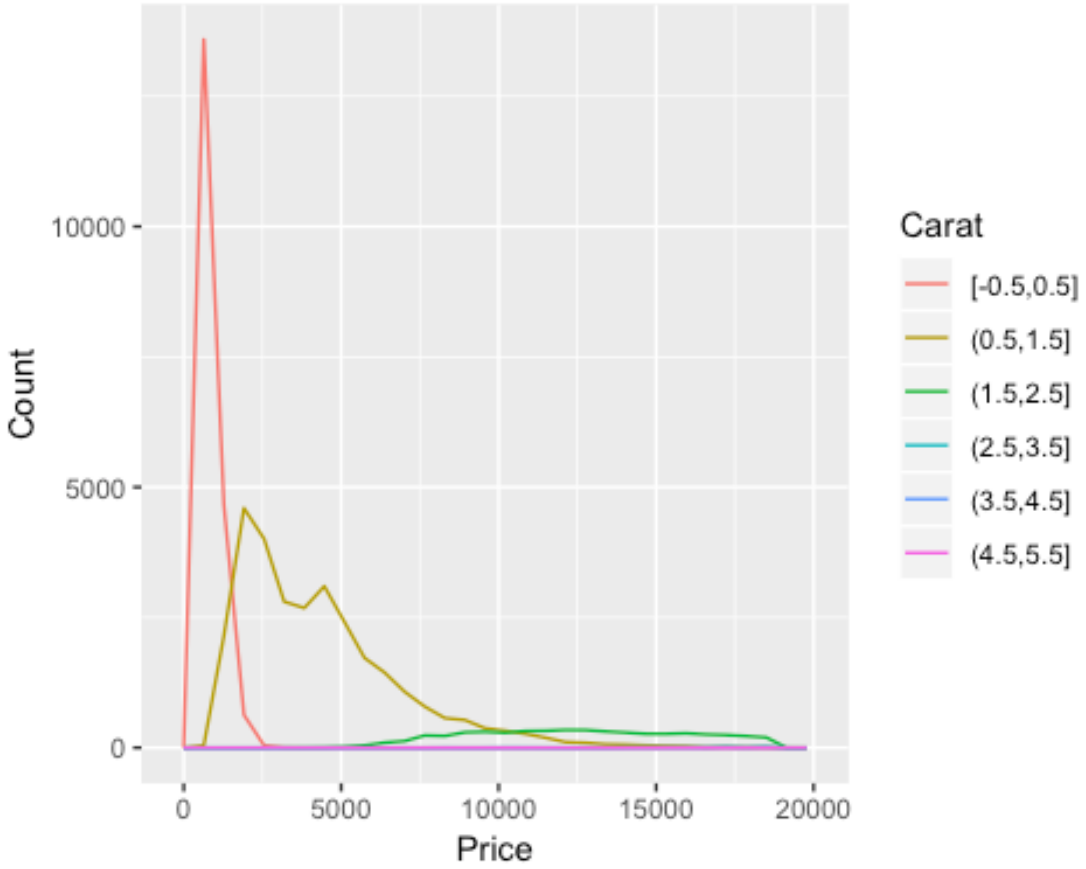

0 보다 작은 캐럿은 없기에 이 범위를 수정해주기 위하여 cut_width()에서 boundary 값을 0 으로 지정해준다.

```
ggplot(diamonds, aes(x=price, color = cut_width(carat, 1, boundary = 0))) + g
eom_freqpoly() +
  labs(x = 'Price', y = 'Count', color = 'Carat')

## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

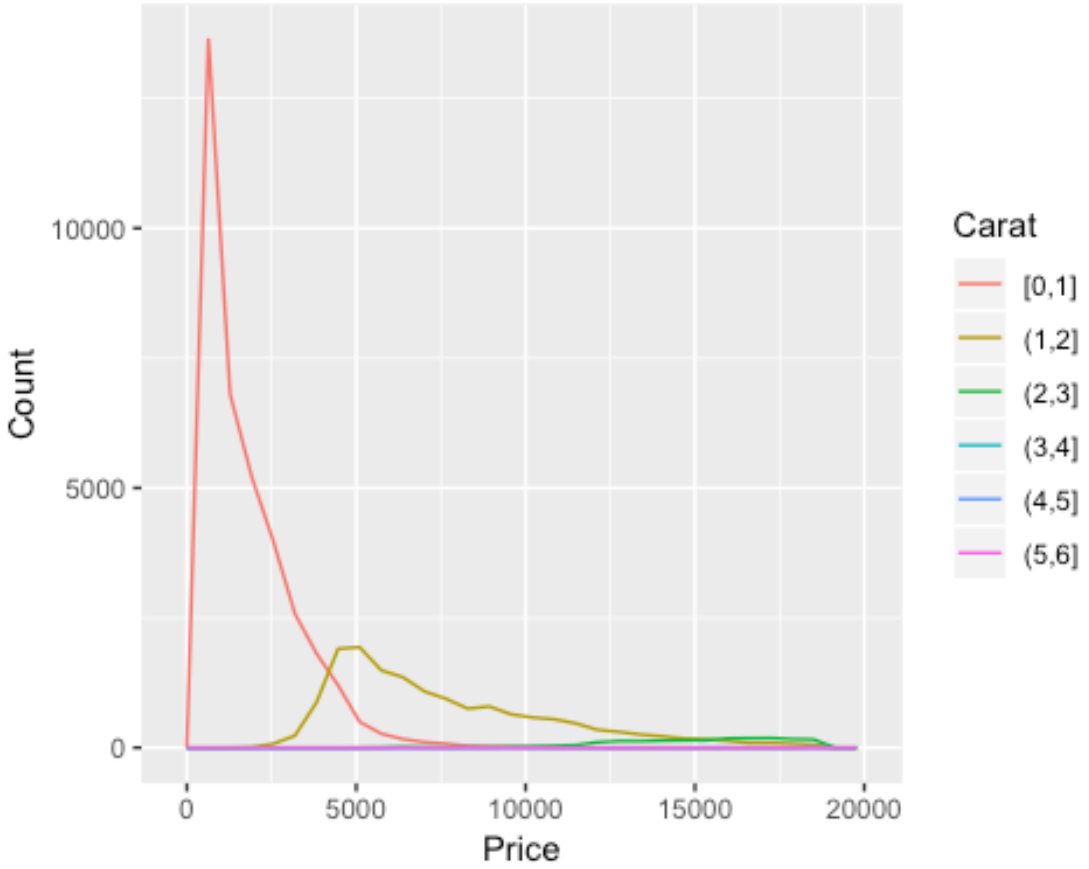

캐럿의 크기가 증가할수록 다이아몬드의 수가 적어진다. 또한 가격도 증가한다.

5.

```
ggplot(diamonds, aes(x=cut_number(price, 10), y = carat)) +
  geom_boxplot() + coord_flip() + xlab('Price')
```

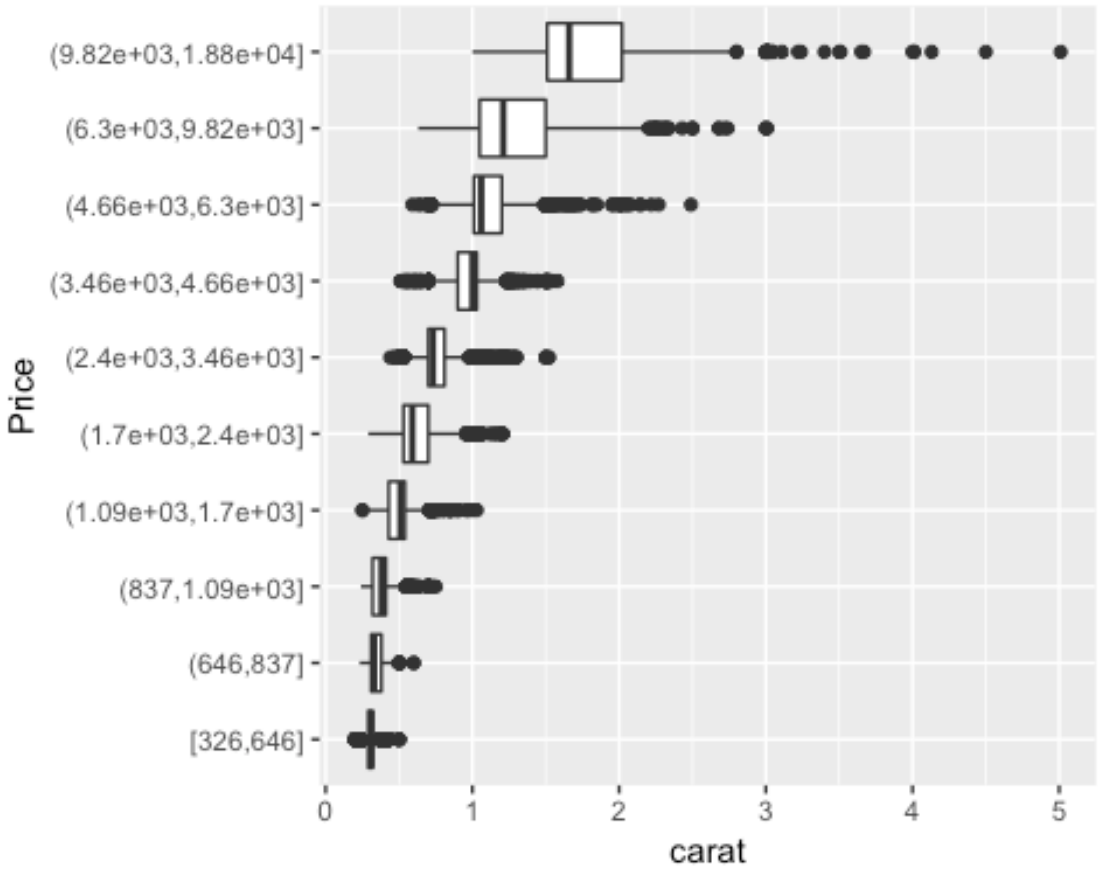

price 를 10 분위로 나눠서 carat 의 boxplot 을 그려보았을때, price 가 증가할수록 carat 도 증가하는 경향을 보인다. 또한 높은 가격대에서 carat 의 outlier 들이 존재한다.

6.

```
ggplot(diamonds, aes(x = cut_number(carat,10), y=price)) + geom_boxplot() +
  coord_flip() + xlab('Carat')
```

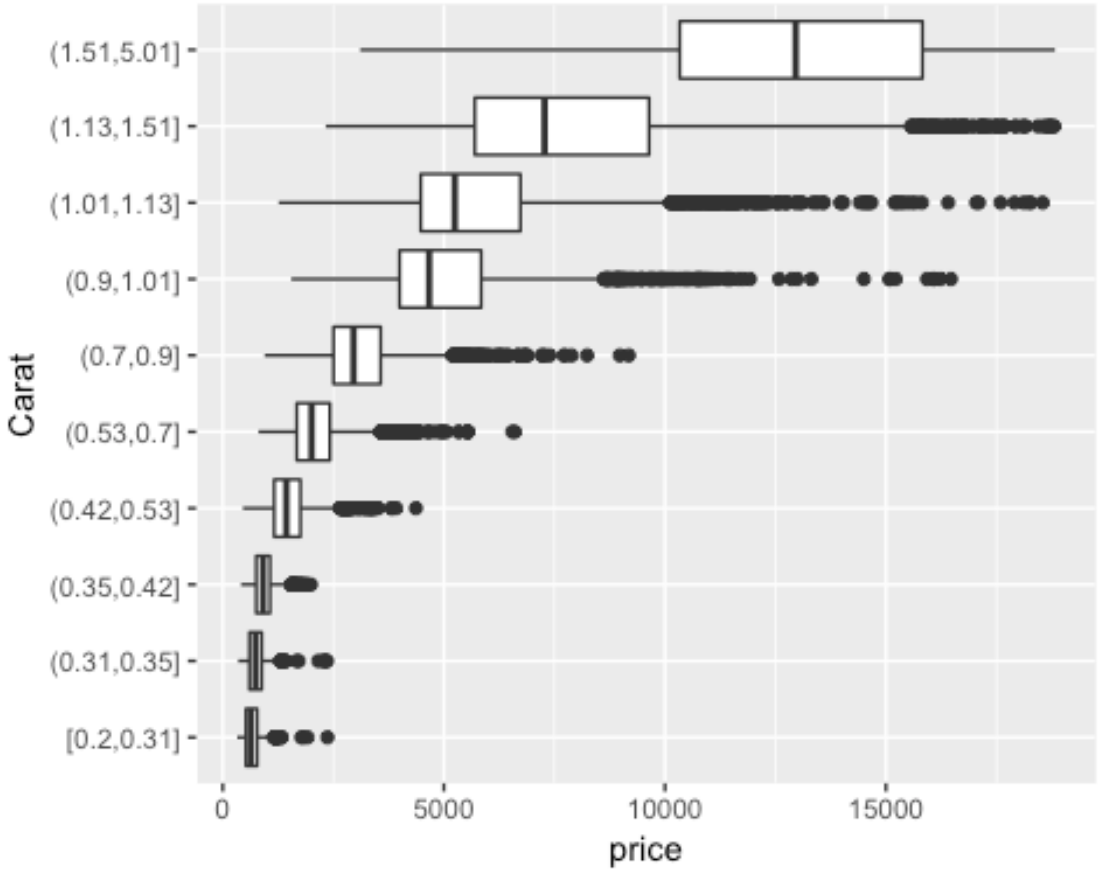

carat 이 클수록 가격대의 distribution 이 넓다. carat 이 크다고 무조건 가격이 높은 것이 아니다. 다이아몬드의 가격 책정의 또다른 기준(clarity, color, etc.)이 있을 것으로 예상된다. 하지만 carat 이 작은 다이아몬드의경우 가격의 변동이 크지 않기에 또 다른 기준(clarity, color, etc.)이 작은 carat 의 다이아몬드에는 영향력이 크지 않다.

7.

table2

```
tb2_cases <- table2 %>% filter(type == 'cases') %>%
  rename(cases = count) %>%
  arrange(country, year)
tb2_population <- table2 %>% filter(type == 'population') %>%
  rename(population = count) %>%
  arrange(country, year)
tb2_per_cap <- tibble(
  year = tb2_cases$year,
  country = tb2_cases$country,
  cases = tb2_cases$cases,
  population = tb2_population$population
```

```
) %>% mutate(cases_per_cap = cases/population * 10000) %>%
  select(country, year, cases_per_cap)
tb2_per_cap <- tb2_per_cap %>%
  mutate(type = 'cases_per_cap') %>%
  rename(count = cases_per_cap)
bind_rows(table2, tb2_per_cap) %>%
  arrange(country, year, type, count)
```

```
## # A tibble: 18 x 4
##    country      year type            count
##    <chr>       <int> <chr>           <dbl>
##  1 Afghanistan  1999 cases         7.45e+2
##  2 Afghanistan  1999 cases_per_cap 3.73e-1
##  3 Afghanistan  1999 population    2.00e+7
##  4 Afghanistan  2000 cases         2.67e+3
##  5 Afghanistan  2000 cases_per_cap 1.29e+0
##  6 Afghanistan  2000 population    2.06e+7
##  7 Brazil       1999 cases         3.77e+4
##  8 Brazil       1999 cases_per_cap 2.19e+0
##  9 Brazil       1999 population    1.72e+8
## 10 Brazil       2000 cases         8.05e+4
## 11 Brazil       2000 cases_per_cap 4.61e+0
## 12 Brazil       2000 population    1.75e+8
## 13 China        1999 cases         2.12e+5
## 14 China        1999 cases_per_cap 1.67e+0
## 15 China        1999 population    1.27e+9
## 16 China        2000 cases         2.14e+5
## 17 China        2000 cases_per_cap 1.67e+0
## 18 China        2000 population    1.28e+9
```

table4a + table4b

```
head(table4a)
```

```
## # A tibble: 3 x 3
##   country     `1999` `2000`
##   <chr>        <int>  <int>
## 1 Afghanistan    745   2666
## 2 Brazil       37737  80488
## 3 China       212258 213766
```

```
head(table4b)
```

```
## # A tibble: 3 x 3
##   country         `1999`     `2000`
##   <chr>            <int>      <int>
## 1 Afghanistan   19987071   20595360
## 2 Brazil       172006362  174504898
## 3 China       1272915272 1280428583
```

```
table4c <- tibble(
  country = table4a$country,
  '1999' = table4a[['1999']] / table4b[['1999']] * 10000, #cases / population
 * 10000
  '2000' = table4a[['2000']] / table4b[['2000']] * 10000
)
table4c
```

```
## # A tibble: 3 x 3
##   country     `1999` `2000`
##   <chr>        <dbl>  <dbl>
## 1 Afghanistan  0.373   1.29
## 2 Brazil       2.19    4.61
## 3 China        1.67    1.67
```

8.

```
stocks <- tibble(
  year = c(2015, 2015, 2016, 2016),
  half = c( 1, 2, 1, 2),
  return = c(1.88, 0.59, 0.92, 0.17)
)

stocks %>% spread(year, return)
```

```
## # A tibble: 2 x 3
##    half `2015` `2016`
##   <dbl>  <dbl>  <dbl>
## 1    1.  1.88   0.920
## 2    2.  0.590  0.170
```

```
stocks %>% spread(year, return) %>%
  gather('year','return','2015','2016')
```

```
## # A tibble: 4 x 3
##    half year  return
##   <dbl> <chr>  <dbl>
## 1    1. 2015   1.88
## 2    2. 2015   0.590
## 3    1. 2016   0.920
## 4    2. 2016   0.170
```

```
stocks %>% spread(year, return) %>%
  gather('year','return','2015','2016', convert = T)
```

```
## # A tibble: 4 x 3
##    half  year return
##   <dbl> <int>  <dbl>
## 1    1.  2015  1.88
## 2    2.  2015  0.590
```

```
## 3    1.  2016  0.920
## 4    2.  2016  0.170
```

gather()을 사용하면 column type(character 로 변환)가 사라진다. 반면 spread 는 유지된다. gather()에 convert 를 사용하면 데이터의 유형을 찾아준다.

9.

```
preg <- tribble(
  ~pregnant, ~male, ~female,
  'yes', NA, 10,
  'no', 20, 12
)

preg %>% gather(male, female, key = 'gender', value = 'count')
```

```
## # A tibble: 4 x 3
##   pregnant gender count
##   <chr>    <chr>  <dbl>
## 1 yes      male     NA
## 2 no       male     20.
## 3 yes      female   10.
## 4 no       female   12.
```

NA obs 삭제

```
preg %>% gather(male, female, key = 'gender', value = 'count', na.rm = T)
```

```
## # A tibble: 3 x 3
##   pregnant gender count
## * <chr>    <chr>  <dbl>
## 1 no       male     20.
## 2 yes      female   10.
## 3 no       female   12.
```

female 에 point

```
preg %>% gather(male, female, key = 'gender', value = 'count', na.rm = T) %>%

  mutate(female = gender == 'female',
         pregnant = pregnant == 'yes') %>%
  select(female, pregnant, count)
```

```
## # A tibble: 3 x 3
##   female pregnant count
##   <lgl>  <lgl>    <dbl>
## 1 FALSE  FALSE      20.
## 2 TRUE   TRUE       10.
## 3 TRUE   FALSE      12.
```

이와같이 3 가지 tibble 로 표현할 수 있다.